

Indeksy i wydajność realizacji zapytań

dr hab. inż. Maciej Grzenda

M.Grzenda@mini.pw.edu.pl

<http://www.mini.pw.edu.pl/~grzendam>

Politechnika Warszawska

Wydział Matematyki i Nauk Informatycznych



**Fundusze
Europejskie**
Wiedza Edukacja Rozwój

**Politechnika
Warszawska**

Unia Europejska
Europejski Fundusz Społeczny



Zadanie 10 pn. „Przygotowanie i uruchomienie nowego kierunku studiów na studiach
II stopnia - Inżynieria i Analiza Danych (IAD)”
realizowane jest w ramach projektu
„NERW PW. Nauka – Edukacja – Rozwój – Współpraca” współfinansowanego ze
środków Unii Europejskiej w ramach Europejskiego Funduszu Społecznego

Wstęp

- Relacyjne bazy danych składują najważniejsze dane dla wielu organizacji
- Czas dostępu do tych danych:
 - ma kluczowy wpływ na wydajność systemów baz danych
 - wynika wprost z czasu realizacji zapytań SQL
- W efekcie:
 - Działania zmierzające do poprawy wydajności realizacji zapytań SQL są integralną częścią przygotowania i utrzymania baz danych
 - Umiejętność użycia indeksów i analizy planów wykonania zapytań jest kluczowa dla programistów i osób przygotowujących rozwiązania analityczne

Zadanie I

- Należy zaproponować indeksy dla każdej z tabel dla problemu poniżej. Dla każdego indeksu należy :
 - zaproponować klucz indeksujący oraz rozważyć wpływ różnej kolejności kolumn w kluczu na czas realizacji zapytań SQL
 - określić czy powinien być to indeks zgrupowany (ang. clustered),
 - określić czy indeks powinien być unikalny
- Opis zagadnienia (scenariusz I z laboratorium nr 2):
 1. Baza danych dla międzynarodowej firmy produkcyjnej o cechach opisanych w poniższych punktach
 2. Firma produkuje dużą liczbę produktów montowanych w różnych krajach
 3. Każdy produkt jest montowany w jednym kraju, z części pochodzących potencjalnie z różnych krajów
 4. Dla każdej części obowiązuje oddzielna cena i okres produkcji
 5. Części, które nie są już produkowane, mają określoną datę zakończenia produkcji
 6. W każdym dziale firmy jest wielu menedżerów sprzedaży.
 7. Są oni przypisani do grup produktów, za które są odpowiedzialni.
 8. Dla każdego produktu jest tylko jeden menedżer produktu. Każdy menedżer działa tylko w jednym dziale.
 9. Istnieje unikalny numer statystyczny dla każdej części nadawany przez każdy kraj oddzielnie.
 10. Nie ma ograniczeń co do wielkości opisu części. Niektóre opisy mogą być wielostronicowe.
 11. Każdy produkt ma globalnie unikalny kod.

Zadanie II

Cel zadania jest identyczny jak dla zadania I – proponowanie indeksów.

Opis zagadnienia (scenariusz II z laboratorium nr 2):

1. Baza danych dla firmy produkcyjnej o cechach opisanych w poniższych punktach
2. Firma jest właścicielem wielu zakładów produkcyjnych
3. Każdy zakład produkcyjny ma dowolnie długi opis, wartość w Euro i składa się z wielu obiektów, które mogą składać się z innych obiektów. Każdy z obiektów może składać się z kolejnych obiektów składowych.
4. Każdy obiekt ma swoje wymiary, odpowiedzialne działy, wymagania zasilania (wysokie/średnie/ niskie napięcie).
5. Każdy obiekt należy do dokładnie jednej kategorii.
6. Każdy obiekt ma przypisanego odpowiedzialnego pracownika.
7. Jeden pracownik może być odpowiedzialny za wiele obiektów.
8. Niektóre obiekty w zakładach produkcyjnych są własnością innych firm.

Zadanie III


Cel zadania jest identyczny jak dla zadania I – zaproponowanie indeksów.

Opis zagadnienia (scenariusz III z laboratorium nr 2):

1. Baza danych dla firmy szkoleniowej o cechach opisanych w poniższych punktach
2. Duża liczba kursów (szkoleń) organizowanych dla różnych klientów.
3. Ten sam kurs może być prowadzony wiele razy dla różnych grup pracowników z różnych firm
4. Każdy uczestnik kursu otrzymuje indywidualny identyfikator podczas pierwszego kursu, w którym uczestniczy
5. Każde szkolenie może być realizowane w języku angielskim lub polskim
6. Niektórzy instruktorzy są pracownikami organizacji TRAIN, ale niektórzy z nich są zatrudniani na podstawie umowy cywilno-prawnej.
7. Za każdy kurs odpowiada dokładnie jeden nauczyciel.
8. Każdy kurs ma dowolny długi opis i własną cenę.


Plan wykonania zapytania – przykład I

select firstname, lastname from employees e where exists (select * from orders o where customerid='ALFKI' and e.employeeid=o.employeeid)



Plan wykonania zapytania ujawnia poszczególne kroki wykonania zapytania i ich koszt. Plan prezentuje również indeksy zastosowane do przygotowania odpowiedzi na kwerendę.

Przykład I – analiza planu wykonania zapytania



The screenshot displays a query plan for a query starting with 'from orders o where'. The plan includes a node labeled 'Index Seek (NonClustered)' which is highlighted in blue. A green arrow points from this node to a properties window titled 'Index Seek (NonClustered)'. The properties window shows various statistics and costs for this operation.

Index Seek (NonClustered)	
Scan a particular range of rows from a nonclustered index.	
Physical Operation	Index Seek
Logical Operation	Index Seek
Actual Execution Mode	Row
Estimated Execution Mode	Row
Storage	RowStore
Actual Number of Rows	6
Actual Number of Batches	0
Estimated Operator Cost	0,0032886 (10%)
Estimated I/O Cost	0,003125
Estimated CPU Cost	0,0001636
Estimated Subtree Cost	0,0032886
Number of Executions	1
Estimated Number of Executions	1
Estimated Number of Rows	6
Estimated Row Size	11 B
Actual Rebinds	0
Actual Rewinds	0
Ordered	True
Node ID	4
Object	[Northwind].[dbo].[Orders].[CustomerID] [o]
Output List	[Northwind].[dbo].[Orders].OrderID

Wyświetlane są szczegóły dotyczące każdego kroku realizacji kwerendy. W zależności od systemu problemem może być nadmierny koszt obliczeniowy (CPU), koszt operacji wejścia-wyjścia lub połączenie kilku problemów.

Informacja o wykorzystaniu indeksu niezgrupowanego

Zadanie nr 1

- Celem jest analiza wydajności wykonania kwerendy:
select * from orders o where
not exists (select * from [order details] od join products p
on p.productid=od.productid where
productname='Scottish Longbreads' and
od.orderid=o.orderid)
and exists (select * from [order details] od join products p
on p.productid=od.productid where
productname='Chocolate' and od.orderid=o.orderid)
- Które kroki wykonania zapytania są najbardziej kosztowne?
- Czy zasadne jest dodanie indeksów?
- W jaki inny sposób można sformułować tekst kwerendy, by uzyskać te same wyniki?

Zadanie nr 2

- Celem jest analiza wydajności wykonania kwerendy:
`select * from customers c where not exists (select * from orders o where o.customerid=c.customerid and exists (select * from [order details] od join products p on p.productid=od.productid where od.orderid=o.orderid and p.productname='Chocolate'))`
- Które kroki wykonania zapytania są najbardziej kosztowne?
- Czy zasadne jest dodanie indeksów?
- W jaki inny sposób można sformułować tekst kwerendy, by uzyskać te same wyniki?

Zadanie nr 3

- Celem jest analiza wydajności wykonania kwerendy, bazującej na widoku OrdersTotal stworzonym w ramach laboratorium nr 5:

```
SELECT OrderId, ProductName, CategoryName, ProductValue,  
SUM(ProductValue) OVER (PARTITION BY ProductName) as  
ProdTotalSale,  
SUM(ProductValue) OVER (PARTITION BY CategoryName) as  
CategoryTotalSale  
FROM OrdersTotal order by ProductName
```

- Które kroki wykonania zapytania są najbardziej kosztowne?
- Czy zasadne jest dodanie indeksów?
- W jaki inny sposób można sformułować tekst kwerendy, by uzyskać te same wyniki?



**Fundusze
Europejskie**
Wiedza Edukacja Rozwój

**Politechnika
Warszawska**

Unia Europejska
Europejski Fundusz Społeczny



Zadanie 10 pn. „Przygotowanie i uruchomienie nowego kierunku studiów na studiach
II stopnia - Inżynieria i Analiza Danych (IAD)”
realizowane jest w ramach projektu
„NERW PW. Nauka – Edukacja – Rozwój – Współpraca” współfinansowanego ze
środków Unii Europejskiej w ramach Europejskiego Funduszu Społecznego