

Wstęp do hurtowni danych i systemów Business Intelligence

dr hab. inż. Maciej Grzenda

M.Grzenda@mini.pw.edu.pl

<http://www.mini.pw.edu.pl/~grzendam>

Politechnika Warszawska

Wydział Matematyki i Nauk Informacyjnych



**Fundusze
Europejskie**
Wiedza Edukacja Rozwój

**Politechnika
Warszawska**

Unia Europejska
Europejski Fundusz Społeczny



Zadanie 10 pn. „Przygotowanie i uruchomienie nowego kierunku studiów na studiach
II stopnia - Inżynieria i Analiza Danych (IAD)”
realizowane jest w ramach projektu
„NERW PW. Nauka – Edukacja – Rozwój – Współpraca” współfinansowanego ze
środków Unii Europejskiej w ramach Europejskiego Funduszu Społecznego

Wstęp

- Dane zgromadzone w bazach relacyjnych mogą i powinny być podstawą przekrojowych analiz
- Analizy takie mogą być realizowane z wykorzystaniem hurtowni danych i systemów Business Intelligence
- Celem laboratorium jest prezentacja wybranych rozwiązań w tym obszarze na przykładzie platformy Ms SQL Server

Wymagania

1. Laboratorium zakłada wykorzystanie Ms SQL Server 2019 Standard Edition lub Enterprise Edition
2. Zarówno usługa SQL Server platformy Ms Windows, jak i usługa SQL Server Analysis Services platformy MS Windows muszą być uruchomione i dostępne. W przypadku problemów z realizacją scenariusza należy uruchomić {Control Panel}/{View local services}, a następnie wybrać kolejno usługi:
 - SQL Server ([Nazwa instancji]) i opcję {Start}
 - SQL Server Analysis Services ([Nazwa instancji]) i opcję {Start}

Uwaga: użycie Ms SQL Server 2019 wynika z dostępnych w laboratorium narzędzi Business Intelligence. W maszynie wirtualnej dostępnej w laboratorium obie w/w usługi powinny być domyślnie uruchomione.

Sprawdzenie wersji oprogramowania

1. Uruchamiamy SQL Server Management Studio
2. Przeprowadzamy połączenie do instancji DBMS, poprzez wybranie opcji:
 1. {Connect}/{Database Engine...}
 2. W opcji {Server name} wybieramy nazwę lokalnej maszyny np. WIN-7KGAL3F2ICE lub wpisujemy localhost
 3. Przeprowadzamy autoryzację z wykorzystaniem (zależnie od konfiguracji środowiska):
 - autoryzacji {Windows Authentication}
 - lub autoryzacji {SQL Server Authentication} i użytkownika sa
3. Wybieramy opcję {New Query} i wprowadzamy w oknie kwerendy polecenie:

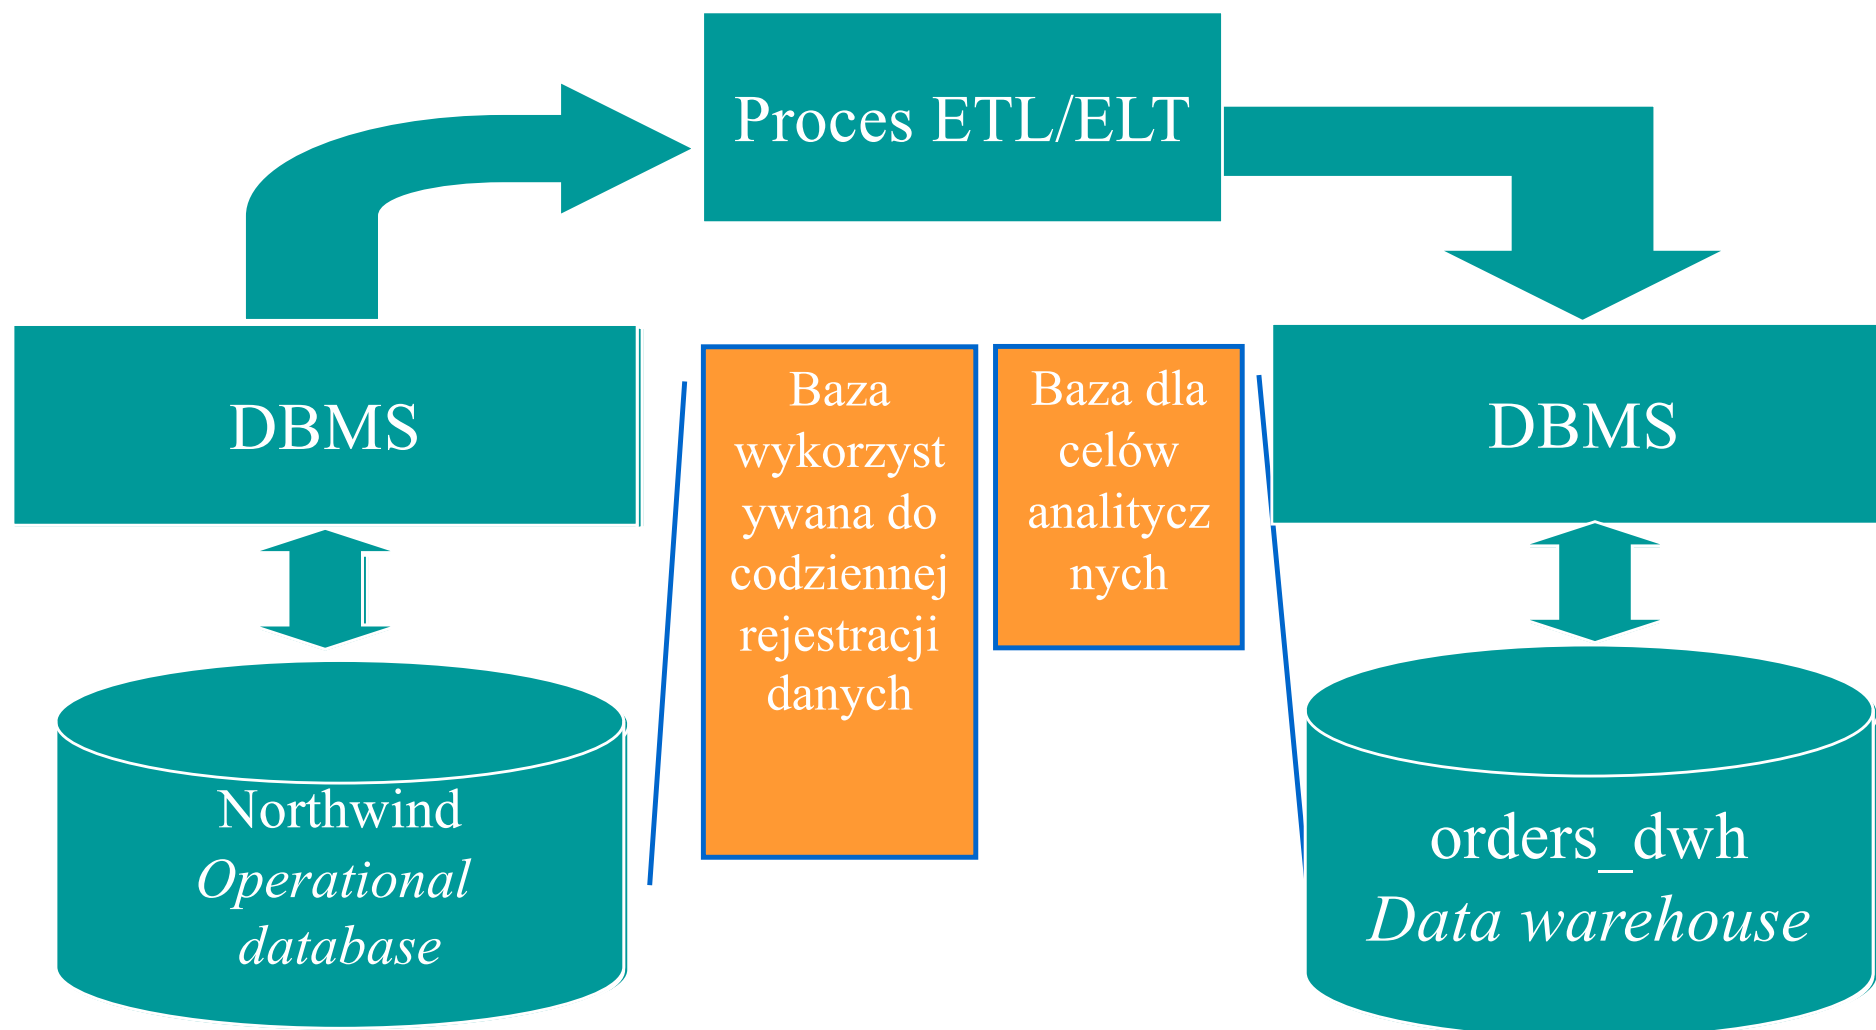
```
SELECT  SERVERPROPERTY('productversion'),  
        SERVERPROPERTY ('edition')
```

**Wartość productversion typu 15.x oznacza wersję
Ms SQL Server 2019.**

Wariant hurtowni danych

- Podczas tego zadania zostanie opracowana relacyjna hurtownia danych, czyli najczęściej używana hurtownia danych. Innymi słowy, opracujemy relacyjny model danych i na jego podstawie zbudujemy kostki danych.
- W przypadku platformy Ms SQL Server inną możliwą opcją jest baza danych kostek SQL Server Analysis Services (SSAS).
- Baza danych kostek SSAS jest możliwą, ale znacznie mniej popularną alternatywą dla hurtowni danych relacyjnych. Zawiera kostki danych zamiast tabel.

Architektura przykładowego rozwiązania




Scenariusz zadania

- Załóżmy, że musimy często analizować dane dotyczące ilości zamówionych produktów. Musi to być analiza w układzie produktów, kategorii produktów, klientów i ich lokalizacji oraz dat zamówienia.
- W celu zapewnienia tej możliwości:
 - stworzymy nową bazę danych pod nazwą orders_dwh
 - przeniesiemy do niej część tabel bazy danych Northwind, aby utworzyć uproszczoną ilustrację struktur hurtowni danych:
 - tabelę faktów o nazwie orders_facts
 - tabele wymiarów
 - utworzymy kostkę danych w bazie analitycznej myDWH.

W rzeczywistości więcej niż jedna baza danych typowo dostarcza dane źródłowe dla hurtowni danych, tworzonych jest wiele tabel faktów i wymiarów, jak również potencjalnie kostek danych. Baza hurtowni danych typowo umieszczana jest na osobnym serwerze.

Przygotowanie środowiska I


- Do realizacji zajęć konieczne będą:
 - Oprogramowanie Ms SQL Server 2019 oraz Ms Visual Studio 2019
- Następnie należy uruchomić Ms Visual Studio 2019 oraz:
 - W przypadku pierwszego uruchomienia wybrać opcję {Continue without code}
 - Wybrać z głównego menu {Extensions}/{Manage Extensions} a następnie {Visual Studio Marketplace}, a po wyszukaniu {Microsoft Analysis Services Projects}, przycisku Download



- Po pobraniu oprogramowania, należy zamknąć w/w okno oraz Visual Studio, co uruchomi VSIX Installer, czyli proces instalacji pakietu Microsoft Analysis Services Projects
- W celu potwierdzenia instalacji należy wybrać {Modify}

Przygotowanie środowiska II

- W kolejnym kroku rozpocznie się proces modyfikacji środowiska Visual Studio 2019 mający na celu dodanie obsługi projektów Analysis Services



- Po jego zakończeniu Visual Studio jest gotowe do obsługi projektów analitycznych

Krok 0: nawiązanie połączenia z usługą DBMS i utworzenie bazy danych


1. Uruchamiamy SQL Server Management Studio
2. Przeprowadzamy połączenie do instancji DBMS, poprzez wybranie opcji:
 1. {Connect}/{Database Engine...}
 2. W opcji {Server name} wybieramy nazwę lokalnej maszyny np. WIN-7KGAL3F2ICE lub wpisujemy localhost
 3. Przeprowadzamy autoryzację z wykorzystaniem (zależnie od konfiguracji środowiska):
 - autoryzacji {Windows Authentication}
 - lub autoryzacji {SQL Server Authentication} i użytkownika sa
3. Tworzymy nową bazę danych orders_dwh w ramach w/w instancji systemu DBMS
4. Kolejne operacje w ramach instancji DBMS wykonujemy w bazie danych orders_dwh

Krok I: utworzenie modelu danych

- Projektujemy strukturę tabeli faktów zamówień oraz towarzyszących jej tabel wymiarów
- Wskazówki:
 - Fakt powinien być atomowy. Zamówienie produktu przez klienta w ramach danego zamówienia to przykład atomowego zdarzenia. W tym przypadku, tabele Orders i [Order Details] stanowią podstawę tabeli faktów.
 - Typowy schemat gwiazdy (ang. *star model*) bazuje na tabelach faktów połączonych z tabelami wymiarów za pomocą kluczy obcych.
 - W analizowanym przypadku (ze względu na ograniczony czas laboratorium) opracujemy jedną tabelę faktów i tabele wymiarów.
Możliwe jest użycie w tym celu gotowego skryptu SQL dostarczonego podczas laboratorium.

Krok I: przykładowy model danych

Model danych bazy
danych orders_dwh
może być
następujący:



Krok II: migracja danych


- Wypełniamy tabelę faktów i tabele wymiarów danymi, przenosząc dane z bazy danych Northwind
- Do migracji danych wykorzystujemy samodzielnie stworzone polecenia SQL lub gotowy skrypt dostarczony w trakcie laboratorium

Na potrzeby tego laboratorium wykorzystujemy do migracji danych zapytania SQL. W rzeczywistości dane podlegają skopiowaniu do hurtowni danych za pomocą narzędzi ETL/ELT pochodzących od dostawców DBMS (np. Microsoft, Oracle) lub innych firm (np. SAS). Proces ETL/ELT typowo jest skomplikowanym procesem – typowo konieczny jest przyrostowy transfer danych i integracja danych pochodzących z różnych źródłowych baz danych. Narzędzia ETL/ELT umożliwiają m.in. wizualizację kolejnych etapów migracji danych.

Krok IIb: przygotowanie bazy danych do celów analitycznych

W drzewie bazy danych,

- wybieramy: {Security}/{Logins}/{New Login...},
- a następnie {Search...} i wskazujemy użytkownika NT SERVICE\MSSQLServerOLAPService zatwierdzając wybór przez {OK}




Nazwa użytkownika to:
NT SERVICE\MSSQLServerOLAPService

Krok IIc: przygotowanie bazy danych do celów analitycznych

W drzewie bazy danych,


- wybieramy:
{Security}/{Logins}/{NT
SERVICE\MSSQLServerOLAP
Service}/{Properties}
- a następnie {User Mapping}
i wprowadzamy ustawienia
jak na zrzucie ekranu



W efekcie wprowadzonych ustawień użytkownik NT SERVICE\MSSQLServerOLAPService będzie miał dostęp do danych zawartych w bazie danych orders_dwh, co pozwoli na dostęp do danych bazy z poziomu np. kostki danych

Szczegółowa architektura tworzonego rozwiązania

Środowisko Visual Studio będzie wykorzystywane przez większość tego scenariusza do definiowania projektu BI (wymiały i moduł danych), wdrażania go w usługach SQL Server Analysis i wizualizacji danych przetwarzanych przez SSAS.




Krok III: stworzenie analitycznej bazy danych

- W SQL Server Management Studio:
 - wybieramy {Connect}/{**Analysis Services**} i przeprowadzamy logowanie do lokalnej instancji usługi z wykorzystaniem Windows Authentication
 - Uwaga: korzystamy z tej samej nazwy sieciowej, co w przypadku usługi DBMS
 - po zalogowaniu wybieramy {Databases}/{New Database...} i tworzymy nową bazę danych o nazwie myDWH
 - W ten sposób stworzyliśmy nową analityczną bazę danych (ang. *analysis services database*)
- Baza analityczna to baza, która stanowi kolekcję obiektów analitycznych takich jak kostki danych i wymiary
- Bliższe szczegóły na temat baz analitycznych:
<https://docs.microsoft.com/pl-pl/analysis-services/multidimensional-models/multidimensional-model-databases-ssas?view=asallproducts-allversions>

Krok IVa: utworzenie projektu analitycznego

- Uruchamiamy {Visual Studio 2019}
- Tworzymy projekt analityczny poprzez:
 - Wybór opcji {Create a new project} lub {File}/{New}/{Project...} (zależnie od istnienia wcześniejszego projektu dostępna będzie jedna z tych opcji)
 - Wybór typu projektu {Analysis Services Multidimensional and Data Mining Project}



Uwaga: SQL Server Management Studio umożliwia przeglądanie i zmiany w bazie analitycznej, ale tylko z poziomu kodu. Do tworzenia rozwiązań Business Intelligence na platformie Ms SQL Server dedykowane jest środowisko Visual Studio, w którym uprzednio należy wykonać dodatkową konfigurację (zgodnie z opisem w początkowej części tej prezentacji). Opis funkcjonalności obu środowisk:

<https://docs.microsoft.com/en-us/analysis-services/multidimensional-models/creating-multidimensional-models-using-sql-server-data-tools-ssdt?view=asallproducts-allversions>


Krok IVb: utworzenie projektu analitycznego

- Następne kroki to:
 - Ustawienie nazwy projektu na: myDWH
 - Utworzenie projektu
- Po utworzeniu projektu, w drzewie projektu wybieramy:
 - myDWH/{Properties},
 - a następnie {Configuration Properties}/Deployment}/{Target}/{Server} w celu ustawienia nazwy instancji DBMS (możliwe jest pozostawienie domyślnej wartości: **localhost**)

Praca w Visual Studio z projektem analitycznym oznacza projektowanie np. kostek danych i wymiarów i umieszczanie ich definicji w analitycznej bazie danych usługi Ms SQL Server Analysis Services. Z tego powodu jedną z kluczowych cech projektu jest lokalizacja serwera analitycznego.

Krok Va: utworzenie źródła danych


- W projekcie stworzonym w poprzednim kroku tworzymy źródło danych (ang. Data Source):
 - Wybieramy {Project}/{New data source...}/{Next>}/{New...}
 - Tworzymy nowe połączenie o ustawieniach jak na rzucie ekranu
 - Wybieramy {Test Connection}, a po potwierdzeniu poprawności połączenia {OK}



Źródło danych wskazuje na lokalizację hurtowni danych, która będzie źródłem danych dla analiz

Krok Vb: utworzenie źródła danych

- Zatwierdzamy wybór właśnie utworzonego połączenia z listy {Data Connections} poprzez wybór {Next>}
- W {Impersonation Information} wprowadzamy ustawienia jak na rzucie ekranu
- Wybieramy {Next>} i finalizujemy utworzenie źródła danych przez {Finish}




Uwaga: w laboratorium może być konieczne użycie opcji podania danych użytkownika i hasła.

Krok VI: utworzenie widoku źródła danych

- Przed utworzeniem kostki danych, konieczne jest zdefiniowanie widoku źródła danych (ang. *data source view*)
- Poprzez zdefiniowanie takiego widoku, możemy:
 - Wybrać tabele ze źródła danych, których dane będziemy analizować
 - Zdefiniować ewentualne dodatkowe relacje w źródle danych
- W celu stworzenia widoku źródła danych:
 1. wybieramy {Next>}/{Project}/{New Data Source View...}
 2. ustawiamy {Orders Dwh} jako źródło danych i wybieramy {Next}
 3. Wybieramy wszystkie trzy tabele (tabela faktu i dwie tabele wymiaru)
 4. Wybieramy {Next>}/{Finish}

Jeden widok źródła danych może stanowić podstawę dla wielu kostek danych zbudowanych z jego wykorzystaniem


Krok VIIa: widok źródła danych



Widok źródła danych pokazuje tabele wybrane do dalszych prac w projekcie, wraz z możliwymi nowymi relacjami, dodanymi na tym etapie. Taki podgląd możemy uzyskać poprzez otwarcie {Orders Dwh.dsv} z węzła {Data Source Views} w drzewie projektu i wybranie tabel w oknie edycji widoku.

Krok VIIb: konfiguracja źródła danych

- Wybieramy Order_facts/{New Named Calculation...}
- Wprowadzamy **CONVERT(VARCHAR (10), OrderId) + '_' + CONVERT(VARCHAR (10), ProductId)** jako definicję nowej dynamicznie wyznaczanej kolumny, która będzie pełnić rolę identyfikatora faktu w sytuacji, gdy tabela faktów zawiera klucz główny złożony




Uwaga: ten krok można pominąć jeśli nasza tabela faktów ma klucz główny złożony z jednej kolumny

Krok VIII: zdefiniowanie wymiarów

- Następnie można zdefiniować wymiary
- W tym przypadku stworzymy wymiary na podstawie następujących danych:
 - Data zamówienia,
 - Klient (Customers),
 - Produkt (Products).
- Aby zdefiniować wymiar, wybieramy opcję {Project}/{New Dimension...}/{Next>}

Jeden widok źródła danych może stanowić podstawę dla wielu kostek danych. Analogicznie, można utworzyć wiele wymiarów z wykorzystaniem danych zawartych w omawianych tabelach np. wymiar miejsca dostawy.

Krok VIIa: utworzenie wymiaru daty zamówienia



Dimension Wizard

Select Creation Method
You can base the dimension on an existing table or generate a new table as the source.


How would you like to create the dimension?

- ☒ Use an existing table
- ☐ Generate a time table in the data source
- ☐ Generate a time table on the server
- ☐ Generate a non-time table in the data source

Template:
(None)

Description:
Create a dimension based on one or more tables in a data source. The attributes that are available for the dimension will depend on the structure of the data in the table.

< Back **Next >** Finish >> Cancel



Dimension Wizard

Specify Source Information
Select a data source and specify how the dimension is bound to it.

Data source view:
Orders Dwh



Main table:
Order_facts

Key columns:
FactName
(Add key column)

< Back **Next >** Finish >> Cancel

Stosujemy ustawienia jak wskazane powyżej oraz na kolejnym slajdzie. Następnie finalizujemy tworzenie wymiaru.


Krok VIIb: utworzenie wymiaru daty zamówienia



Wybieramy atrybuty istotne dla danego wymiaru. W kolejnym kroku nadajemy wymiarowi nazwę {Order Date}


Krok VIIc: określenie hierarchii dla wymiaru daty zamówienia

- W drzewie projektu / poddrzewie {Dimensions} poprzez dwukrotne kliknięcie na wymiarze daty zamówienia, otwieramy edytor wymiarów.
- Poprzez przeciągnięcie i upuszczenie atrybutów, definiujemy hierarchię:



W ten sposób zadeklarowaliśmy, że należy grupować zamówienia z daną datą. To bardzo prosty przykład. W rzeczywistości typowo tworzone są tabele wymiaru daty, by np. przypisać do daty informację, czy reprezentuje dzień roboczy czy świąteczny, jak również by z datą związać kwartał lub miesiąc jako jawny atrybut dostępny do wyboru dla użytkownika i umożliwiający grupowanie faktów.

Krok VIIId: umieszczenie projektu jako części bazy analitycznej




Kliknięcie na {Process} powoduje wdrożenie projektu (ang. deploy), czyli umieszczenie definicji wymiaru w bazie danych Analysis Services. Należy twierdząco odpowiedzieć na kolejne pytania o kontynuację i wybrać {Run...}

W efekcie projekt BI został wdrożony w bazie danych usług Analysis Services. Źródła danych i definicje wymiarów zostały umieszczone na serwerze. Uwaga: problemy z wykonaniem tego kroku mogą być związane z brakiem właściwej konfiguracji wstępnej użytkownika bazy danych Ms SQL Server o nazwie {NT SERVICE\MSSQLServerOLAPService}

Krok VIIIe: podgląd danych wymiaru

- Wybór narzędzia {Browser} edytora wymiaru prezentuje dane tego wymiaru:



Dla każdej daty obecnej w faktach wyświetlane są wszystkie zamówienia z tą datą.

Krok VIII f: utworzenie wymiaru kontrahenta

Dimension Wizard

Specify Source Information
Select a data source and specify how the dimension is bound to it.

Data source view:
Orders Dwh

Main table:
Customers

Key columns:
CustomerID
(Add key column)

CustomerID

< Back **Next >** Finish >> Cancel



Dimension Wizard

Select Dimension Attributes
Specify dimension attributes and select Enable Browsing to surface them as hierarchies.



Available attributes:

☒ Attribute Name	☒ Enable Browsing	Attribute Type
☒ Customer ID	☒	Regular
☒ Company Name	☒	Regular
☐ Contact Name	☐	Regular
☐ Contact Title	☐	Regular
☐ Address	☐	Regular
☒ City	☒	Regular
☒ Region	☒	Regular
☒ Postal Code	☒	Regular
☒ Country	☒	Regular
☐ Phone	☐	Regular
☐ Fax	☐	Regular

< Back **Next >** Finish >> Cancel


Postępujemy analogicznie jak w przypadku wymiaru daty. Wprowadzamy ustawienia pokazane powyżej i na następnym slajdzie. Edycję kończy wdrożenie zmian na serwerze (przycisk Process)

Krok VIIg – zdefiniowanie hierarchii dla wymiaru kontrahenta



W tym przypadku hierarchia definiuje grupowanie według krajów, miast, kodów pocztowych i nazw klientów. To przykład decyzji, które musi podjąć analityk z uwzględnieniem znajomości danych. W analizowanym przypadku liczba konsumentów jest dość ograniczona, a kod pocztowy nie grupuje wielu konsumentów. Stąd można go usunąć z hierarchii. W innym przypadku zasadne mogłoby być dodanie np. grupowania po województwie. Uwaga: przed wyświetleniem danych z użyciem opcji {Browser} konieczne jest wdrożenie (opcja {Process})

Krok VIIIh: zdefiniowanie wymiaru produktu




Specify Source Information
Select a data source and specify how the dimension is bound to it.

Data source view:
Orders Dwh

Main table:
Products

Key columns:
ProductID
(Add key column)
ProductID

< Back Next > Finish >> Cancel



Select Dimension Attributes
Specify dimension attributes and select Enable Browsing to surface them as hierarchies.



Available attributes:

☒ Attribute Name	☒ Enable Browsing	Attribute Type
☒ Product ID	☒	Regular
☒ Product Name	☒	Regular
☒ Category Name	☒	Regular
☐ Quantity Per Unit	☐	Regular
☐ Unit Price	☐	Regular
☐ Units In Stock	☐	Regular
☐ Units On Order	☐	Regular
☐ Reorder Level	☐	Regular
☐ Discontinued	☐	Regular

< Back Next > Finish >> Cancel

Stosujemy ustawienia takie, jak zaprezentowane powyżej. Podobnie, jak dla wcześniejszych wymiarów, użycie Finish kończy edycję

Krok VIIIi: zdefiniowanie hierarchii dla wymiaru produktów




W tym przypadku hierarchia bazuje na kategorii produktu i nazwie produktu.

Krok IX: utworzenie kostki danych

- Wybieramy {Project}/{New Cube...}/{Next>} a następnie:
 - wybieramy {use existing tables}/{Next>}
 - wybieramy {Order facts} w {Measure Group Tables}/{Next>}
 - wybieramy {Order Facts Count} /{Next>}
 - wybieramy wszystkie stworzone wymiary/{Next>}
 - Nadajemy kostce nazwę {Orders_cube}/{Finish}
- Podobnie jak w przypadku wymiarów, wykorzystujemy narzędzie {Process} by wdrożyć kostkę na serwerze Analysis Services

Należy podkreślić, że nie wszystkie rozwiązania Business Intelligence wymagają kostek danych. Inne popularne rozwiązanie to bezpośrednie raportowanie z tabel hurtowni danych. W takich przypadkach nie zostaną utworzone kostki danych.

Krok IX: Wyniki



The screenshot shows the SAP BW Design Studio interface. The 'Orders_cube' cube is selected in the left pane. The 'Customers' dimension is chosen in the 'Dimension' dropdown, and 'Customers.Hierarchy' is selected in the 'Hierarchy' dropdown. The 'Order Facts Count' measure is added to the 'Measures' list. The resulting table displays the following data:

Country	City	Category Name	Order Facts Count
Argentina	Buenos Aires	Beverages	7
Argentina	Buenos Aires	Condiments	3
Argentina	Buenos Aires	Confections	8
Argentina	Buenos Aires	Dairy Products	6
Argentina	Buenos Aires	Grains/Cereals	1
Argentina	Buenos Aires	Produce	4
Argentina	Buenos Aires	Seafood	5
Austria	Graz	Beverages	18
Austria	Graz	Condiments	13

Aby uzyskać taki raport, wystarczy wybrać {Browser} przeciągnąć i upuścić miary oraz wymiary.

Podsumowanie

- Laboratorium ilustruje możliwości zapewniane przez:
 - hurtownie danych: integracja danych do uproszczonego w stosunku do wersji znormalizowanej modelu danych tzn. wersji 3NF
 - Systemy Business Intelligence:
 - Zdefiniowanie wymiarów, w tym wymiarów hierarchicznych
 - Zdefiniowanie kostek danych
 - Interaktywna analiza danych bez konieczności tworzenia kodu SQL
- Hurtownie danych i systemy BI stanowią ważną część infrastruktury informatycznej i zarazem analitycznej współczesnych przedsiębiorstw
- Modelowanie danych na potrzeby hurtowni danych, jak również użycie systemów BI to osobny, rozległy obszar wiedzy



**Fundusze
Europejskie**
Wiedza Edukacja Rozwój

**Politechnika
Warszawska**

Unia Europejska
Europejski Fundusz Społeczny



Zadanie 10 pn. „Przygotowanie i uruchomienie nowego kierunku studiów na studiach
II stopnia - Inżynieria i Analiza Danych (IAD)”
realizowane jest w ramach projektu
„NERW PW. Nauka – Edukacja – Rozwój – Współpraca” współfinansowanego ze
środków Unii Europejskiej w ramach Europejskiego Funduszu Społecznego